

指輪型デバイスにおけるアクティブ音響センシングを用いた無音発話認識手法の提案

b1022007 情報システムコース
渡邊研究室 浅古尚登


背景

コロナ禍により、オンライン通話が一般化


→公共の場でも音声入力のニーズが高まっている

音声アシスタントAIが発達

→入力が増える機会が増える



音声入力は便利だが、屋外での使用は抵抗がある。




音声を発さずに発話内容を認識する手法

Silent Speech Interface(SSI)が注目されている

関連研究 1

外耳道に伝わる声を使用^[1]

- カナル型イヤホンのマイクでSSI



小さい声が漏れる

口腔内の変化を認識^[2]

- 医療用超音波プローブでSSI



専用のセンサが必要

[1] 福本 雅朗. Whisphone: ささやき声で入力できるイヤホン. In 第 32 回インタラクティブシステムとソフトウェアに関するワークショップ論文集 (WISS 2024), Japan, 2024. WISS. Microsoft.

[2] Naoki Kimura, Michinari Kono, and Jun Rekimoto. Sottovoce: An ultrasound imaging-based silent speech interaction using deep neural networks. In Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems (CHI '19), Glasgow, Scotland, UK, 2019. Association for Computing Machinery.


関連研究 2

超音波でSSI [3]

スマートウォッチのマイクとスピーカで実現

人間の聞こえない周波数の音を使用

- 公共の場での使用には心理的抵抗が残る
- 読唇術で入力内容が漏洩する危険性がある



研究目的

公共の場でもプライバシーに配慮したSSIを実現するため

指輪型デバイスでSSIを実現する

口を隠して無音で入力を可能にすることで、社会的受容性と実用性の両立を目指す。



現在地

〒040-0035 北海道函館市松風町...

車 19分 43分 2時間 32分

✓ 有料道路を使わない

19分

22:30 に到着 : 最速ルート (通常より少なめの交通量)

開始 経由地を追加 保存済み

Google Maps

6





自宅までの経路を表示

研究概要

1. 指輪によるSSI認識


マイクとスピーカーを搭載した指輪を制作

指輪を装着し、口に手を添える態勢でデータ収集
(アクティブ音響センシング)

発話ごとの特徴を機械学習で分類

2. 社会的受容性の検証


指輪型デバイスと腕時計で無音発話を行った様子を比較



制作したデバイス

指輪を3Dプリンターで作製

高周波数対応のマイク、スピーカーを搭載



超音波信号の設計

FMCW信号を使用 (Frequency Modulated Continuous Wave)

- 反射波との周波数差から対象物までの距離や速度を測る技術

可聴音を超える周波数に設定

- 帯域：20kHz ~ 25kHz
- 長さ：6ミリ秒

先行研究より

約1.8mmの変化を検出可能

データの取得方法

「再生」「停止」「次へ」「戻る」「音量アップ」「音量ダウン」

- 音声操作で用いられる一般的な単語

6単語 × 50データ × 7人 = 2100データ





声を出さずに口と舌だけ動かす

データの分析方法

エコープロファイル

- 反射波の強さを距離と時間で表した図（縦軸：距離、横軸：時間）[3]

反射面を5 cm~15cmに動かした実験：





データの分析方法

エコープロファイル

- 反射波の強さを距離と時間で表した図（縦軸：距離、横軸：時間）[3]

反射面を5 cm~15cmに動かした実験：



口の動きと反射波の変化

再生


停止

次へ


戻る

音量アップ

音量ダウン



特徴が出やすいように前処理を施す
(一例)



前処理


- 3種類の前処理をする
 - 1.エッジを強調
 - 2.小さい変化を強調
 - 3.大きい動きを残す

データ拡張

- 時間のずれに強いモデルにする

2D CNN で分類

- 特徴を自動で抽出して分類




結果

精度：0.91

混同行列 (右図)


縦軸：正解 横軸：予測

対角線上に数値が多いほど、
正しく分類できていることを示す。




同じ語数の単語が間違いやすい

- 「音量アップ」と「音量ダウン」を誤認識



同じ母音の単語が間違いやすい

- 「停止」と「再生」を誤認識
(eii) (aiei)



社会的受容性の比較

5段階のアンケート調査を実施

- 指輪型デバイスと腕時計で無音発話を行った様子の動画を比較

10~20代の男女 10名



社会的受容性の比較

自己視点評価 or 他者視点評価 × 6つの場面

「屋外」「オフィス」「家」「スポーツ中」「仕事中」「休憩中」

([1]全く好ましくない～[5]非常に好ましい)





ほとんどの場面で **4** 前後の評価

腕時計との比較 **有意差なし**

(自己視点評価：t[9]=0.66, p=.52 他者視点評価t[9]=0.66, p=.52)

- [1]全く好ましくない
- [2]あまり好ましくない
- [3]どちらとも言えない
- [4]やや好ましい
- [5]非常に好ましい



今後の展望

認識精度の向上

- 同じ語数、似た母音を含む単語の精度の向上

社会受容性の調査

- より多くの回答者を対象に社会受容性を詳細に調査

音素単位で認識

- 音声入力のように使用可能することを目指す

まとめ

目的

公共の場でもプライバシーに配慮したSSIを実現するため
指輪型デバイスでのSSI手法を提案する

結果

2D CNNで分類 - 精度：0.91

社会的受容性の検証

- ほとんどの場面で4前後の評価